

 **PREVIGASTO**



@NEUROHACK

**PREDICE.
PLANEA.
PROSPERA**

An integral solution for hey banco

Problemática RESUELTA.

Determinar **recurrencia**, **lugar** y **temporalidad** en la que un cliente realice un consumo.

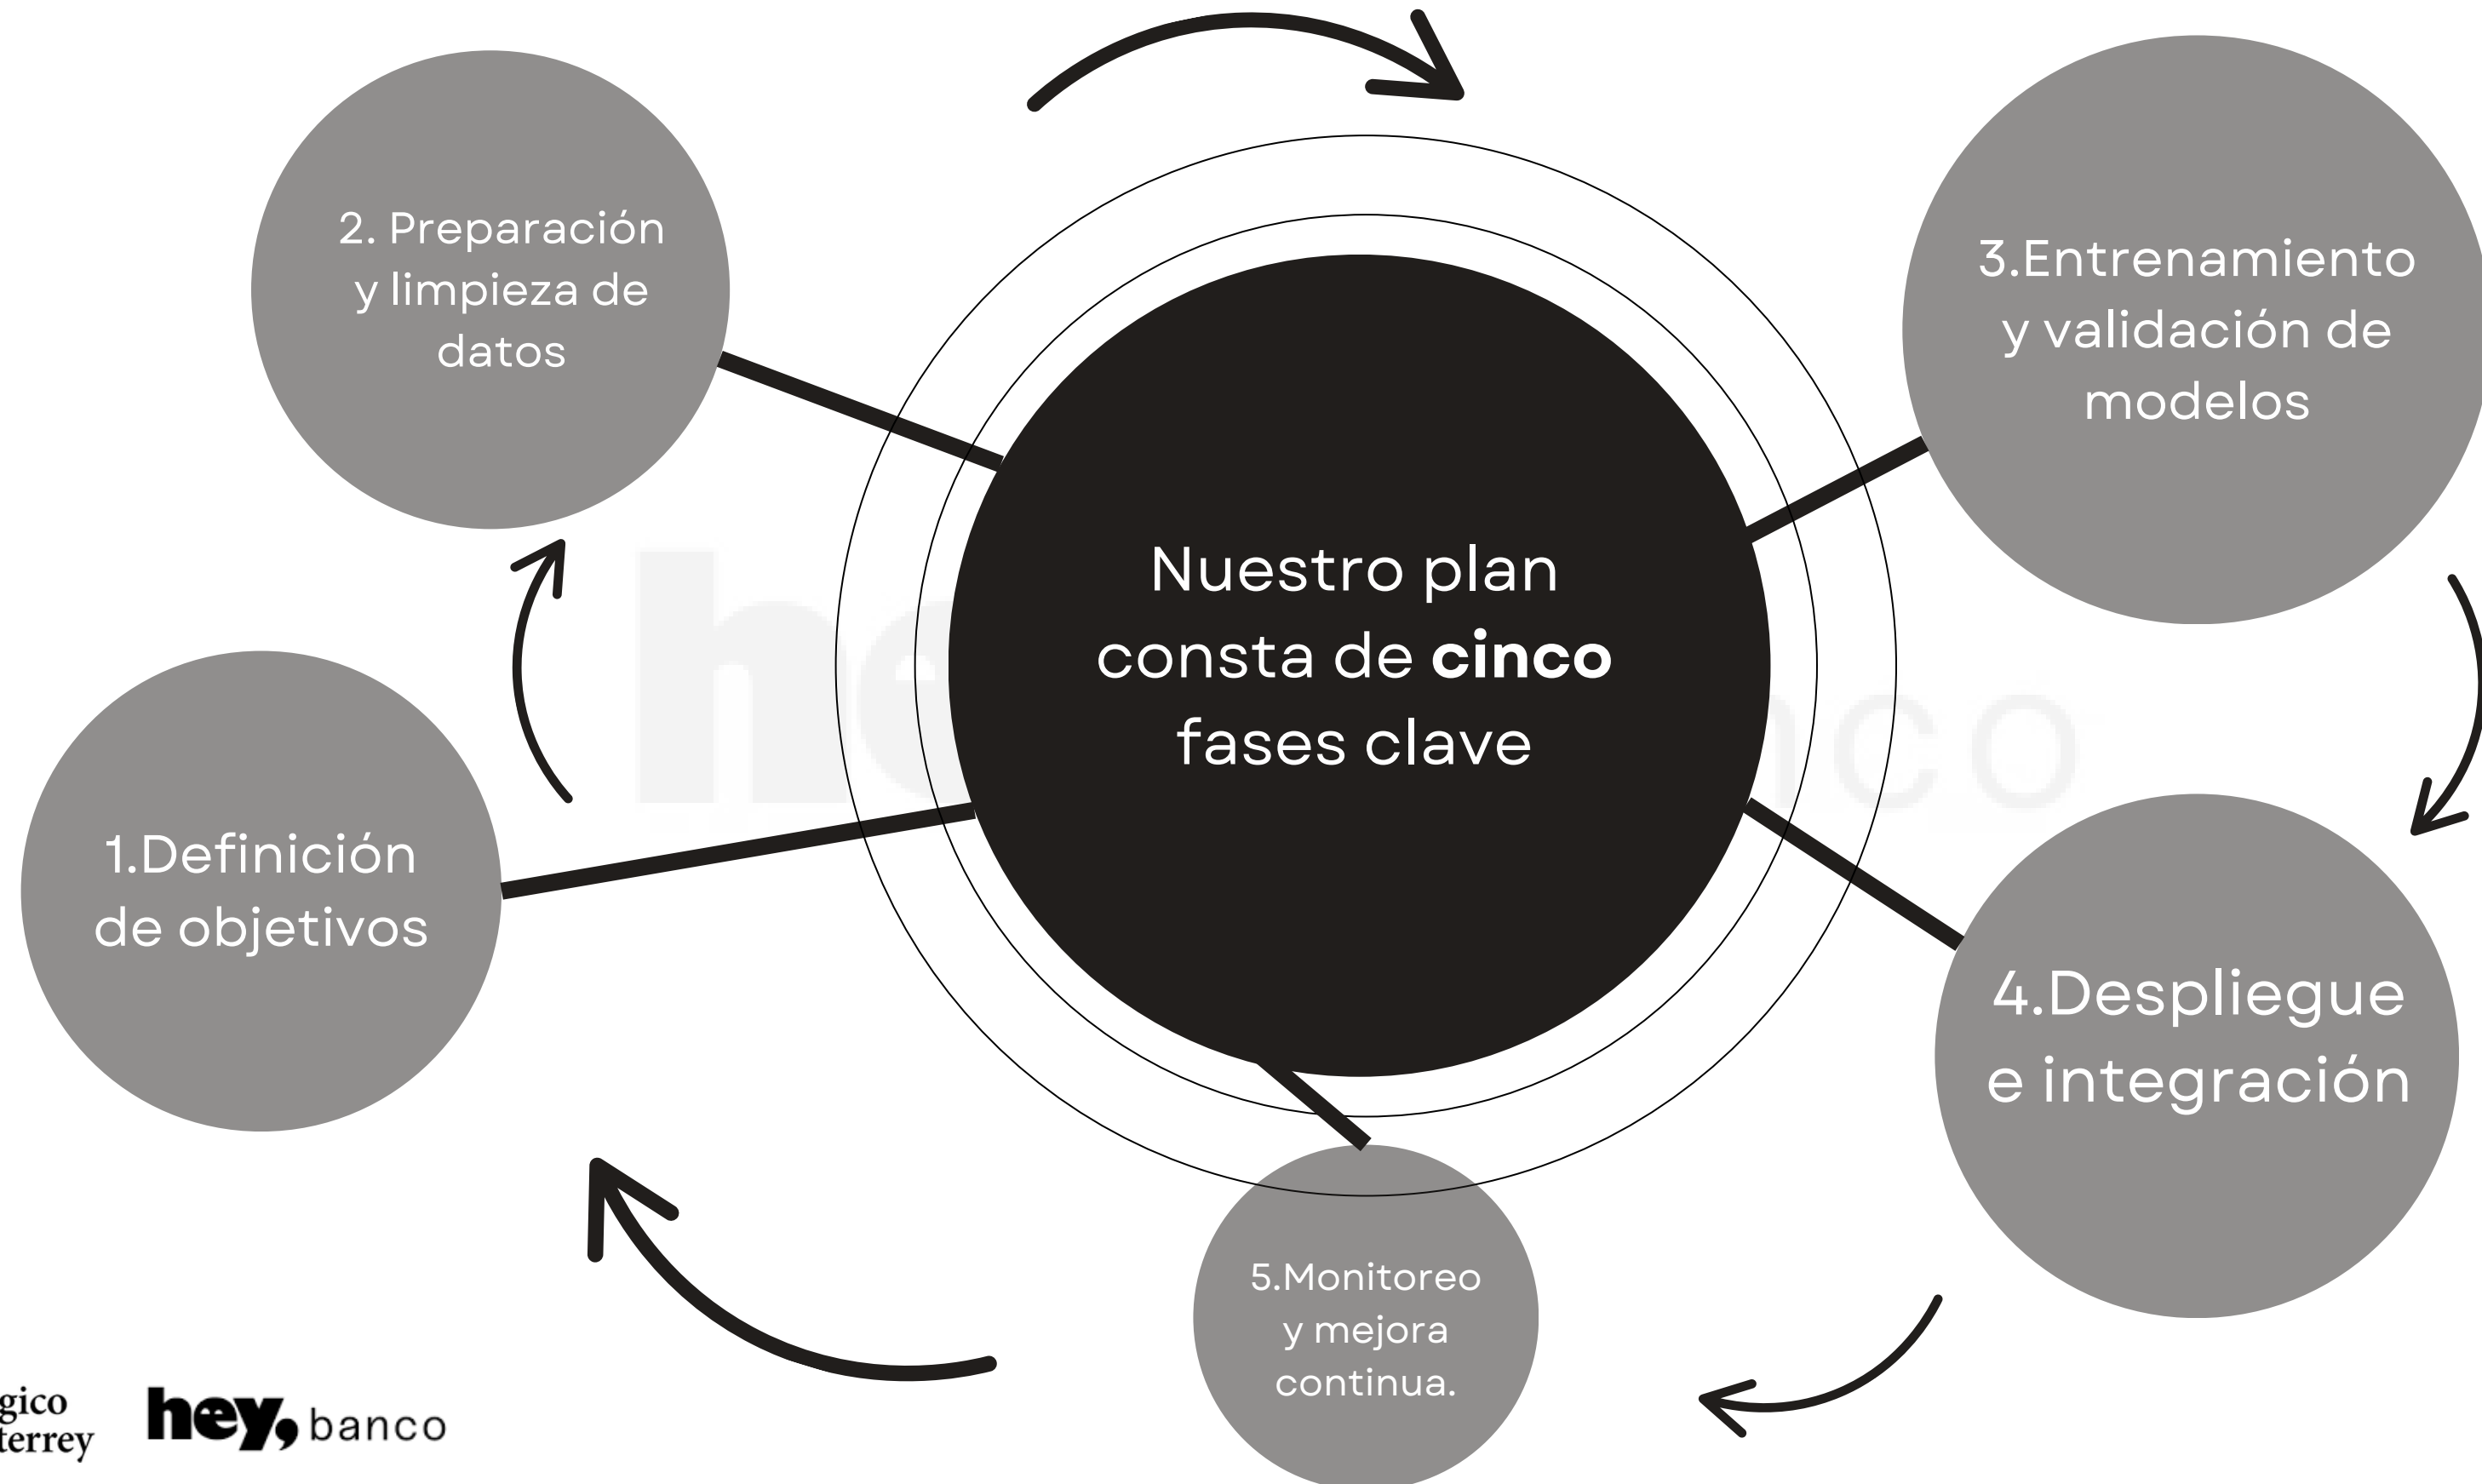
Modelado Predictivo por Segmento:

- Clasificación en áreas clave: comercio y recompra
- Regresión aplicada a: tiempo y monto
- Predicciones individualizadas para cada variable, permitiendo entender mejor el comportamiento del cliente

Serie de tiempo 2022



Plan de **Accion**




Booking.com

Predicción de cancelaciones de reservas

Indicador	Antes del modelo	Con LGBMClassifier
Tasa de predicción de cancelación	~62%	84%
Reducción de impacto financiero	–	15% menos pérdidas por cancelaciones inesperadas
Tiempo de inferencia	>500 ms	<100 ms por reserva


Estructura 1.1

Variable
id
fecha
comercio
giro_comercio
tipo_venta
monto
fecha_nacimiento
fecha_alta
id_municipio
id_estado
tipo_persona
genero
actividad_empresarial
edad
historial
dia_del_anio


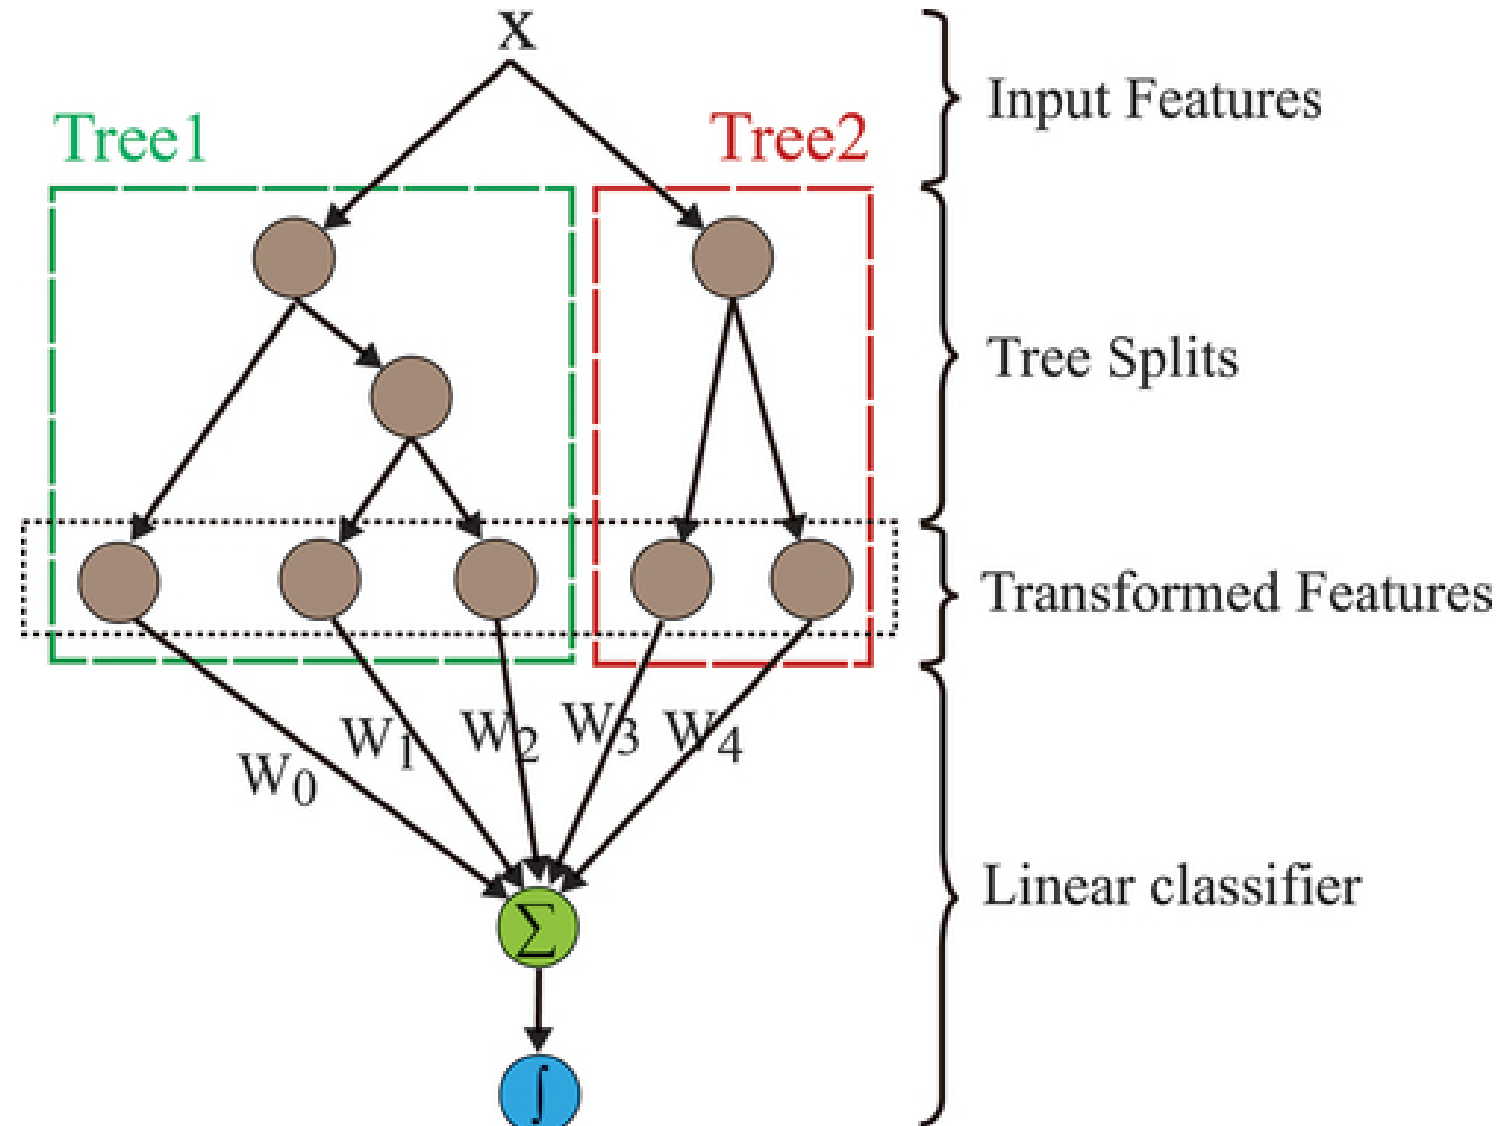


Recompra
Tiempo_dias
monto_estimado
comercio


Estructura 1.1.2



Evaluation of the Model



Desempeño Modelo



Mejoras del Modelo

Mejoras posibles:

1. Precisión en variables categóricas como “comercio”

- Aunque se predice el comercio como clase, hay 49 categorías, y la precisión tiende a diluirse. Puede ser necesario agrupar o reetiquetar (reducción dimensional o target encoding).

2. Generalización y sobreajuste

- Aunque Optuna mejora resultados en el conjunto de prueba, existe riesgo de overfitting si el modelo es muy específico a los datos actuales. Se recomienda validación cruzada o time series split si los datos son temporales.

3. Validación más robusta

- Incorporar validación cruzada estratificada o por tiempo si se desea evitar sobreajuste.

Costos Preliminar

Componente	Costo Inicial Estimado (USD)	Costo Mensual Estimado (USD)
Amazon EC2 (Django)	\$0 (uso bajo demanda)	\$30 – \$40
Amazon RDS (PostgreSQL)	\$0 – \$5 (configuración inicial)	\$20 – \$25
Amazon Lambda (ML)	\$0 (se carga desde ECR)	\$0 – \$1
Amazon ECR (contenedor)	\$5 – \$10 (carga inicial modelo)	\$0.10
Amazon S3	\$0 – \$5 (dependiendo de carga)	\$0.20 – \$1
Amazon API Gateway	\$0	\$0.50 – \$2
Amazon Cognito	\$0 – \$10 (configuración inicial)	\$0 – \$1
Frontend (React + Tailwind)	\$100 – \$300 (desarrollo inicial)	Hosting externo o en S3 (ver nota)
DevOps & Configuración	\$300 – \$500 (único)**	–
TOTAL	≈ \$400 – \$800 (único)	≈ \$50 – \$70 mensual

Anexos 1.0 ROI

Concepto	Valor estimado	Detalles
Costos Iniciales Totales	\$600 USD	Desarrollo + configuración + carga de modelo + puesta en marcha
Costos Mensuales Operativos	\$60 USD	AWS + mantenimientos mínimos
Tiempo de operación proyectado	12 meses	Proyección para 1 año completo
Ejecución del modelo	2 veces al mes (24 veces/año)	En Lambda, con resultados almacenados en RDS/S3
Tiempo manual previo por tarea	4 horas por ejecución	Estimación conservadora (clasificación, reporte o análisis manual)
Costo de hora-hombre promedio	\$15 USD	Asumiendo salario mensual de \$2400 USD (40h semana)
Reducción en errores y retrabajo	25% menos	Gracias a modelo ML y automatización

Anexos 1.1 Ahorro Esperado

Categoría	Cálculo	Ahorro Estimado
Ahorro en horas-hombre	24 ejecuciones × 4h = 96 horas/año	
Valor económico del tiempo ahorrado	96 h × \$15/h =	\$1,440 USD
Ahorro adicional por menor error	25% de \$1,440	\$360 USD
Total Ahorros Anuales	\$1,440 + \$360	\$1,800 USD

Anexos 1.3 Costo Anual y Payback Period

Concepto	Cálculo	Total
Costos Iniciales	Único	\$600
Costos Mensuales × 12	\$60 × 12	\$720
Costo Total Año 1	\$600 + \$720	\$1,320 USD

- **Ahorro mensual** estimado: $\$1,800 / 12 = \150
- Tiempo para **recuperar** los \$600 **iniciales**:
 - 4 meses

Gracias || **hey,** banco